

Diagnostico y Modelos Predictivos de una Planta Solar Fotovoltaica

Analisis de Senales Electricas de 24 Inversores (2017-2023)

Alumno:	Ameth de Jesus Mendez Toledo
Matricula:	233363
Institucion:	Universidad Politecnica de Chiapas
Curso:	Mineria de Datos
Fecha:	Julio 2026
Dataset:	2107_electrical_data.csv

Resumen

Este documento presenta un proceso completo de mineria de datos -comprension, exploracion, preparacion, modelado y evaluacion- sobre 2107_electrical_data.csv, un dataset de 632,952 registros (5 minutos de resolucion, ~6 años) con las senales electricas de los 24 inversores de una planta solar fotovoltaica.

Tras identificar y corregir problemas de calidad (nulos por inversores fuera de linea, una asimetria estructural entre inversores y un error tipografico en un nombre de columna), se desarrollaron tres lineas de analisis complementarias: (1) un modelo supervisado que predice la potencia AC total de la planta a partir de sus senales de entrada, comparando Regresion Lineal, Random Forest y un Perceptron Multicapa (MLP) entrenado con PyTorch; (2) un analisis no supervisado que segmenta los 24 inversores por perfil de desempenio (K-Means sobre componentes de PCA) y detecta registros anomalos (Isolation Forest); y (3) un modelo de forecasting (Holt-Winters) que pronostica la energia semanal generada, aprovechando la estacionalidad anual del recurso solar.

El mejor modelo supervisado (Regresion Lineal) alcanzo un R^2 de 0.9992 en el conjunto de prueba, y el modelo de forecasting supero al baseline ingenuo estacional con un MAPE de 21.79%. El periodo analizado abarca de noviembre de 2017 a noviembre de 2023.

1. Introduccion

Una planta solar fotovoltaica genera, a traves de sus inversores, un volumen continuo de mediciones electricas (corriente y voltaje DC de entrada, corriente, voltaje y potencia AC de salida) que reflejan tanto las condiciones ambientales (irradiancia solar) como el estado operativo del equipo. En este trabajo se analiza el dataset 2107_electrical_data.csv, que contiene mediciones cada 5 minutos de los 24 inversores de una planta solar durante aproximadamente 6 años (noviembre de 2017 a noviembre de 2023). No se proporciono un problema especifico a resolver: el conjunto fue explorado para identificar oportunidades de analisis, resultando en tres lineas de trabajo (supervisado, no supervisado y forecasting).

Planteamiento del problema

El dataset no incluye variables meteorologicas externas (irradiancia, temperatura ambiente), por lo que toda la informacion disponible para diagnostico y prediccion proviene unicamente de las senales electricas internas de la planta. Esto plantea tres preguntas concretas:

- Es posible predecir la potencia AC total de la planta a partir de las senales de entrada de los inversores? (aprendizaje supervisado)
- Existen inversores con un perfil de desempenio distinto al resto de la flota, o intervalos anomalos que sugieran una falla o degradacion? (aprendizaje no supervisado / diagnostico)
- Puede anticiparse la energia que producira la planta en las proximas semanas a partir de su historial? (forecasting)

Objetivo general

Aplicar un proceso completo de ciencia de datos sobre el dataset electrico de la planta solar, para diagnosticar el comportamiento de sus variables y generar modelos predictivos que apoyen la toma de decisiones.

Metodologia utilizada

- **Carga y exploracion:** pandas, revision de tipos, nulos, duplicados y rango temporal.
- **Preparacion:** imputacion justificada de nulos, correccion de error tipografico, variables derivadas y escalamiento (StandardScaler).
- **Aprendizaje supervisado:** Regresion Lineal, Random Forest y MLP (PyTorch, optimizador Adam, perdida MSE).
- **Aprendizaje no supervisado:** perfilado de inversores, PCA, K-Means e Isolation Forest.
- **Forecasting:** descomposicion estacional y Holt-Winters sobre la serie semanal de energia, contra un baseline ingenuo estacional.

2. Descripcion del Dataset

El archivo 2107_electrical_data.csv contiene mediciones electricas cada 5 minutos de los 24 inversores de una planta solar fotovoltaica.

Caracteristica	Valor
Registros	632,952
Columnas	120 (119 numericas + 1 marca de tiempo)
Periodo	2017-11-01 a 2023-11-07 (~6 años)
Frecuencia de muestreo	5 minutos
Filas duplicadas	0

Estructura de columnas

Cada uno de los 24 inversores aporta hasta 5 senales: corriente DC (24 columnas), voltaje DC (23, el inversor 05 no tiene esta columna), corriente AC (24), voltaje AC (24) y potencia AC (24).

Problemas de calidad detectados

- **Valores nulos: 183,372 celdas nulas (0.24% del total), en 114 de 119 columnas numericas. Corresponden a intervalos en que un inversor especifico estuvo fuera de linea (entre 366 y 1,728 registros faltantes por equipo).**
- **Asimetria estructural: el inversor 05 carece de la columna de voltaje DC presente en los otros 23 inversores.**
- **Error tipografico: la columna de potencia AC del inversor 15 se llama inv_15_ac_power_iinv_149653 (nota 'iinv' en vez de 'inv').**

3. Limpieza y Preparacion de Datos


```
df = df.rename(columns={
    'inv_15_ac_power_iinv_149653': 'inv_15_ac_power_inv_149653'
})
df[feature_cols] = df[feature_cols].fillna(0)
power_cols = [c for c in df.columns if 'ac_power' in c]
df['total_ac_power'] = df[power_cols].sum(axis=1, min_count=1)
df['hour'] = df['measured_on'].dt.hour
df['month'] = df['measured_on'].dt.month
```

- **Correccion de nombre de columna:** se corrigio el typo para que la columna siga el mismo patron y pueda incluirse en operaciones agregadas.
- **Imputacion de nulos con 0:** un nulo corresponde a un inversor fuera de linea (sin comunicacion); imputar con la media simularia generacion inexistente.
- **Variables derivadas:** total_ac_power (suma de las 24 potencias), hour, month, year.
- **Filtro de horas sin generacion:** solo para el modelo supervisado, se excluyen las horas nocturnas (todas las senales son 0 por definicion fisica), reduciendo el conjunto de 632,952 a 309,308 filas (48.9%).
- **Escalamiento:** StandardScaler en variables de entrada y objetivo antes de entrenar el MLP y la Regresion Lineal.


4. Analisis Descriptivo (EDA)

Estadistico	total_ac_power (W)
count	632,952
media	156.32
desv. estandar	230.96
minimo	0.00
percentil 25	0.00
mediana	0.00
percentil 75	291.60
maximo	721.61

La mediana de total_ac_power es 0: mas de la mitad de los registros corresponden a horas sin generacion (nocturnas o inversores fuera de linea). El % de lecturas en cero por inversor varia entre 52.5% y 59.2%.




Distribuciones de potencia AC total, corriente DC y voltaje AC.




Distribucion de potencia AC por inversor (horas con generacion > 0).

La mediana de potencia por inversor oscila entre 8.9 W (inversor 07) y 13.9 W (inversor 20). Los inversores 04 y 07 destacan por su mediana baja y por valores maximos anomalos (~104-105 W frente a ~30 W del resto de la flota).




Perfil diurno (izq.) y mensual (der.) de la potencia AC total.



Potencia AC total de la planta - promedio diario, 2017-2023.

5. Relaciones entre Variables



Correlacion de Spearman entre variables agregadas de planta.

Par de variables	Spearman rho
total_dc_current -- total_ac_power	0.987
total_ac_current -- total_ac_power	0.984
avg_ac_voltage -- total_ac_power	0.890
hour -- total_ac_power	0.111

Las corrientes DC y AC correlacionan casi perfectamente con la potencia total ($\rho > 0.98$), consistente con $P = V \times I$. Llama la atención que la correlación entre hour y total_ac_power es baja (0.111) pese al patrón diurno evidente: esto no indica ausencia de relación, sino una limitación del coeficiente de Spearman, que solo capta relaciones monótonas -la potencia sube y luego baja a lo largo del día, una relación de campana, no monótona.

6. Aprendizaje Supervisado

Definicion del problema predictivo


Variable objetivo: total_ac_power (potencia AC total de la planta), continua => problema de regresion. Variables de entrada (98): corriente DC (24), voltaje DC (23), corriente AC (24) y voltaje AC (24) por inversor, mas hour, month y year. Conjunto de datos: 309,308 registros con generacion > 0, particionados 70/15/15 en entrenamiento/validacion/prueba.

Seleccion de modelos

- **Regresion Lineal: baseline interpretable.**
- **Random Forest Regressor: 150 arboles, profundidad maxima 14.**
- **MLP (PyTorch): 256->128->64->1, ReLU, Dropout; optimizador Adam, perdida MSE, salida lineal (sin Softmax, reservado para clasificacion).**

Entrenamiento

El MLP se entreno hasta 60 epocas con early stopping (paciencia 10), gradient clipping (norma maxima 1.0), scheduler ReduceLROnPlateau, y restauracion de los pesos de la epoca con menor error de validacion (no la ultima). El entrenamiento se detuvo por early stopping en la epoca 16.




Curva de aprendizaje del MLP - MSE de entrenamiento y validacion.

La curva evidencia una perdida de validacion inestable y con picos de gran magnitud respecto a la de entrenamiento, sintoma de sensibilidad del MLP a valores extremos aislados (ver picos anomalos de potencia en los inversores 04 y 07, Seccion 7). La restauracion de la mejor epoca mitiga, pero no elimina, este efecto.


Evaluacion y comparacion de modelos

Modelo	RMSE (W)	MAE (W)	R2
Regresion Lineal	6.94	5.10	0.9992
Random Forest	8.16	4.86	0.9988
MLP (PyTorch)	51.33	44.52	0.9536



Potencia real vs. predicha en el conjunto de prueba, tres modelos.

Modelo seleccionado: Regresion Lineal, por presentar el menor RMSE (6.94 W) y el mayor R2 (0.9992), superando a Random Forest (RMSE 8.16 W) y al MLP (RMSE 51.33 W). Este resultado, a primera vista contraintuitivo (el modelo mas simple supero a los dos mas complejos), se explica en la Seccion de Discusion: la potencia AC de cada inversor es aproximadamente el producto de su corriente y voltaje, una relacion que 98 variables lineales ya aproximan muy bien, dejando poco margen a modelos no lineales y exponiendolos a mayor varianza.



Top 15 variables por Permutation Importance sobre Random Forest.


La variable mas importante por un margen amplio es inv_11_dc_current, seguida de inv_20_dc_current; el resto del top 15 esta dominado por corrientes AC de distintos inversores. Ninguna variable de voltaje aparece entre las 15 mas relevantes: la corriente, proporcional a la irradiancia solar instantanea, es el factor que realmente explica las variaciones de potencia.

7. Aprendizaje No Supervisado y Diagnostico

A diferencia de la Sección 6, aquí no se predice un valor conocido: el objetivo es descubrir estructura -grupos de inversores con desempeño similar y registros que se desvían del comportamiento esperado- sin usar etiquetas.

Perfilado de inversores y clustering

Para cada uno de los 24 inversores se construyó un perfil (energía total, potencia media y máxima, desviación estándar, % de tiempo en cero durante horas de luz). Los perfiles se estandarizaron, se proyectaron a 2 componentes principales (90.0% de varianza explicada) y se agruparon con K-Means ($k=3$).




Clustering de los 24 inversores por perfil de desempeño (PCA 2D).

Cluster	Inversores	Perfil
0 (n=14)	08,09,10,11,12,13,14,15,17,18,20,22,23,24	Mayor energía, menor % en cero
1 (n=8)	01,02,03,05,06,16,19,21	Energía y % en cero intermedios
2 (n=2)	04, 07	Atípico: menor energía, mas tiempo en cero, picos anómalos

El cluster 2 (inversores 04 y 07) se separa claramente: son los dos con mayor % de tiempo en cero durante horas de luz (36.5% y 39.2%, los más altos de toda la flota) y los únicos cuya potencia máxima (~104-105 W) casi cuadruplica el máximo típico (~30 W) del resto. Esta coincidencia -señalada tanto por el boxplot comparativo como por el clustering no supervisado- es evidencia consistente de que los inversores 04 y 07 son candidatos prioritarios a revisión de mantenimiento.

Deteccion de anomalias a nivel de registro

Se aplico Isolation Forest sobre la relacion hora del día -- potencia AC total, con contaminacion esperada de 2%, para senalar intervalos de 5 minutos cuyo comportamiento se aparta de la envolvente diurna típica.




Registros anómalos (rojo) respecto al patrón diurno esperado.


Se marcaron 8,405 registros como anómalos (1.99% del total de horas con luz, consistente con la tasa de contaminación configurada). Este análisis complementa al modelo supervisado: mientras este predice cuanta potencia se genera, el análisis no supervisado identifica que inversores o intervalos requieren atención, sin necesidad de historial de fallas etiquetado.

8. Forecasting - Series de Tiempo

Se busca pronosticar la energia semanal generada por la planta. La serie de 5 minutos se agrego a frecuencia semanal (suma de total_ac_power), produciendo una serie de 313 semanas (2017-2023).



Energia AC total generada por semana (2017-2023).




Descomposicion aditiva: tendencia, estacionalidad anual y residuo.

La descomposicion confirma una estacionalidad anual marcada y regular superpuesta a una tendencia de mas largo plazo; el residuo conserva variabilidad no explicada, atribuible a condiciones climaticas semanales no registradas en el dataset.

Modelos comparados

Se reservo el ultimo año (52 semanas) como prueba: (1) Baseline ingenuo estacional (valor de la misma semana del año anterior); (2) Holt-Winters (suavizado exponencial triple, captura tendencia y estacionalidad).

Modelo	RMSE	MAE	MAPE (%)
Naïve estacional	110,050.42	81,013.18	29.64
Holt-Winters	66,010.72	52,908.83	21.79



Pronostico semanal - real vs. baseline ingenuo vs. Holt-Winters.

Modelo seleccionado: Holt-Winters, con una reducción de ~40% en RMSE y MAE, y de casi 8 puntos porcentuales de MAPE (21.79% vs. 29.64%) respecto al baseline ingenuo. La principal limitación es que el modelo es univariado: no incorpora variables meteorológicas externas ni eventos de mantenimiento programado, por lo que su desempeño se degrada en semanas climáticamente atípicas.

9. Evaluacion General

Linea de analisis	Metrica principal	Resultado
Supervisado (potencia)	R2 / RMSE	0.9992 / 6.94 W
No supervisado (diagnostico)	% registros anomalos	1.99%
Forecasting (energia semanal)	MAPE	21.79%

10. Discusion

Sobre el aprendizaje supervisado

El hallazgo mas relevante es que el modelo mas simple (Regresion Lineal) fue el de mejor desempenio, por un margen claro sobre Random Forest y el MLP. Esto no es un fracaso de los modelos complejos: la potencia AC es aproximadamente el producto de corriente y voltaje, y con 98 variables de entrada una combinacion lineal ya aproxima muy bien esa relacion casi algebraica -hay poco margen para que la capacidad adicional de un modelo no lineal reduzca el error, y si margen para que introduzca varianza (el Dropout del MLP penaliza un problema con poco ruido real). Es un recordatorio: la complejidad del modelo debe elegirse segun la naturaleza de la relacion subyacente.

Sobre el aprendizaje no supervisado

El agrupamiento revelo que no todos los inversores se comportan igual pese a recibir, en principio, la misma irradiancia. Es consistente con diferencias reales de operacion: sombreado parcial, degradacion desigual o fallas intermitentes de comunicacion. La deteccion de anomalias, al no requerir historial de fallas etiquetado, es especialmente util en un escenario realista.

Sobre el forecasting

Holt-Winters aprovecha la fuerte estacionalidad anual del recurso solar, pero es univariado: no sabe nada sobre nubosidad, mantenimiento programado o expansion de capacidad. Su error se concentra, previsiblemente, en semanas con condiciones climaticas atipicas.

Limitaciones generales

- El dataset no incluye variables meteorologicas externas que explicarian una porcion relevante de la variabilidad no capturada por los modelos.
- La imputacion de nulos con 0 asume que todo valor faltante corresponde a un inversor apagado; razonable dado el contexto fisico, pero no verificable de forma independiente.
- El Random Forest se entreno sobre una submuestra de 150,000 registros (de 309,308 disponibles) para mantener tiempos de entrenamiento razonables.
- El numero de clusters ($k=3$) se fijo de forma exploratoria; un analisis con series de tiempo completas por inversor podria refinar la segmentacion.

11. Conclusiones

Se aplico un proceso completo de ciencia de datos -comprension, exploracion, preparacion, modelado y evaluacion- sobre el dataset electrico de una planta solar fotovoltaica de 24 inversores (632,952 registros, ~6 años a 5 minutos).

- Se identificaron y corrigieron problemas de calidad de datos concretos (nulos por inversores fuera de linea, asimetria estructural entre inversores y un error tipografico en un nombre de columna), documentando cada transformacion.
- Se demostro que la potencia AC total puede predecirse con altisima precision ($R^2 = 0.9992$) a partir unicamente de las senales electricas de entrada. De forma reveladora, el modelo mas simple (Regresion Lineal) supero a Random Forest y al MLP, evidenciando que la relacion es casi algebraica ($P = V \times I$) y que mayor complejidad no implica mejor desempenio en ese regimen.
- El analisis no supervisado segmento los 24 inversores en 3 clusters e identifico a los inversores 04 y 07 como un grupo claramente atipico (mayor tiempo fuera de linea, picos de potencia anomalos); ademas, se marco un 1.99% de los registros diurnos como anomalos.
- El pronostico semanal con Holt-Winters aprovecho la fuerte estacionalidad anual de la generacion solar, superando a un baseline ingenuo estacional (MAPE 21.79% vs. 29.64%).

Aportacion del trabajo

Mas alla de aplicar un algoritmo aislado, este trabajo integra sobre un mismo dataset industrial de alta frecuencia las tres perspectivas de mineria de datos solicitadas -prediccion supervisada, diagnostico no supervisado y forecasting- mostrando como cada una responde a una pregunta de negocio distinta (cuanto se genera, que componentes requieren atencion, y cuanto se generara a futuro) a partir de la misma fuente de datos electricos, sin depender de variables externas ni de un historial de fallas etiquetado.

Anexos

A. Fuente del dataset

Archivo 2107_electrical_data.csv: mediciones electricas cada 5 minutos de 24 inversores de una planta solar fotovoltaica (nov-2017 a nov-2023), proporcionado por la catedra de Minería de Datos.

B. Reproducibilidad

- Notebook: plan_mineria.ipynb (raiz del repositorio)
- Figuras exportadas en: figuras/
- Entorno: Python 3.14, pandas, numpy, scikit-learn, statsmodels, PyTorch, seaborn, matplotlib
- Colocar 2107_electrical_data.csv en la raiz del repositorio (junto al notebook) antes de ejecutar; no se incluye en el repositorio por su tamaño (~400 MB).

C. Referencias

- The pandas development team. pandas: powerful Python data analysis toolkit. <https://pandas.pydata.org/>
- scikit-learn developers. scikit-learn: Machine Learning in Python. <https://scikit-learn.org/>
- PyTorch Foundation. PyTorch Documentation. <https://pytorch.org/docs/>
- statsmodels developers. statsmodels: Statistical Models, Hypothesis Tests, and Data Exploration in Python. <https://www.statsmodels.org/>
- Winters, P. R. (1960). Forecasting Sales by Exponentially Weighted Moving Averages. Management Science, 6(3), 324-342.
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. 2008 Eighth IEEE International Conference on Data Mining, 413-422.